

MACHINE LEARNING BÁSICO

Introducción al Machine Learning

Conceptos fundamentales para estudiantes de pregrado

Contenido

01

Introducción al Machine Learning

Conceptos básicos, tipos de aprendizaje y flujo de trabajo

02

Preprocesamiento de Datos

Transformando datos brutos en información útil

03

Aprendizaje Supervisado: Regresión

Regresión lineal simple, múltiple y evaluación

04

Aprendizaje No Supervisado

Clustering y algoritmo K-Means

05

Ética en Machine Learning

Sesgos, implicaciones éticas y responsabilidad

01

Introducción al Machine Learning

Conceptos básicos y fundamentos del aprendizaje automático

Geometric
Data Science



¿Qué es el Machine Learning?

Definición

El **Machine Learning** o Aprendizaje Automático es una rama de la Inteligencia Artificial que permite a las computadoras **aprender de datos** sin ser programadas explícitamente para cada tarea.

En lugar de seguir instrucciones fijas, los algoritmos identifican patrones en los datos y toman decisiones basadas en ese aprendizaje.

Programación Tradicional vs ML

Programación Tradicional:

Datos + Reglas → Resultados

Machine Learning:

Datos + Resultados → Reglas/Modelo

Ejemplos Cotidianos

✉️ Filtros de spam

VOICE Asistentes virtuales

MOVIE REEL Recomendaciones Netflix

CART Recomendaciones Amazon

Tipos de Machine Learning

👉 Supervisado

Aprende de datos **etiquetados** con respuestas correctas.

Ej.: Clasificar emails como spam/no spam

TW No Supervisado

Encuentra patrones en datos **sin etiquetas**.

Ej.: Agrupar clientes por comportamiento

⊕ Por Refuerzo

Aprende mediante **prueba y error** recibiendo recompensas.

Ej.: Entrenar agentes para jugar ajedrez



Tipos de Aprendizaje Automático



Supervisado

El algoritmo aprende de datos **etiquetados** que contienen las respuestas correctas. El objetivo es aprender una función que mapee entradas a salidas conocidas.

Clasificación

Predice **categorías o clases** discretas.

- Email: spam / no spam
- Imagen: gato / perro / pájaro
- Tumor: benigno / maligno

Regresión

Predice valores **continuos numéricos**.

- Precio de una casa
- Temperatura del día
- Ingresos de una empresa



No Supervisado

El modelo trabaja con datos **sin etiquetas**, buscando identificar patrones, estructuras o agrupaciones ocultas en los datos.

Clustering

Agrupa datos **similares** en clústeres.

- Segmentación de clientes
- Agrupar artículos similares
- Identificar comunidades

Reducción de Dimensionalidad

Reduce **complejidad** manteniendo información.

- Visualización de datos
- Compresión de imágenes
- Selección de características



Por Refuerzo

Un **agente** aprende mediante **prueba y error** en un entorno, recibiendo recompensas o penalizaciones por sus acciones.

Ciclo de Aprendizaje

1. Agente observa el estado
2. Toma una acción
3. Recibe recompensa/penalización
4. Ajusta su estrategia
5. Repite el proceso

Aplicaciones

- Juegos (AlphaGo, Dota 2)
- Robótica y control
- Trading algorítmico



Flujo de Trabajo Básico de un Proyecto de ML

1 Identificar el Problema

Definir claramente qué se quiere resolver y los objetivos del proyecto.

2 Recolección de Datos

Obtener datos relevantes de bases de datos, APIs, sensores, encuestas, etc.

3 Preprocesamiento

Limpiar datos, manejar valores faltantes, normalizar, codificar variables.

4 EDA

Análisis Exploratorio: visualizar distribuciones, detectar patrones y anomalías.

5 Selección del Modelo

Elegir algoritmo adecuado según el tipo de problema y datos disponibles.

6 Entrenamiento

Ajustar parámetros del modelo usando datos de entrenamiento.

7 Evaluación

Validar el rendimiento con datos de prueba usando métricas apropiadas.

8 Ajuste

Optimizar hiperparámetros para mejorar el rendimiento del modelo.

9 Deployment

Implementar el modelo en producción para hacer predicciones en tiempo real.

10 Monitoreo

Vigilar el rendimiento continuo y reentrenar si es necesario.



Proceso Iterativo: El flujo de trabajo de ML no es lineal. Según los resultados de evaluación, es común volver a etapas anteriores (preprocesamiento, selección de modelo, etc.) para mejorar el rendimiento.

02

Preprocesamiento de Datos

Transformando datos brutos en información útil para el modelo



Preprocesamiento de Datos

¿Por Qué Es Importante?

Los datos del mundo real son **sucios, incompletos y inconsistentes**. Sin preprocesamiento, incluso los algoritmos más avanzados producirán resultados engañosos o inexactos.

El preprocesamiento **mejora la calidad de los datos**, lo que se traduce en modelos más precisos y confiables.

Problemas Comunes

- Valores faltantes
- Datos duplicados
- Formatos inconsistentes
- Outliers (valores atípicos)
- Escalas diferentes

Beneficios

- Mayor precisión del modelo
- Mejor rendimiento
- Reducción de sesgos
- Menos sobreajuste
- Entrenamiento más rápido

Limpieza de Datos

- ✓ **Manejar valores faltantes:** Imputar con media/mediana/moda o eliminar registros
- ✓ **Eliminar duplicados:** Identificar y remover registros repetidos
- ✓ **Corregir errores:** Tipos, formatos incorrectos, valores fuera de rango

Transformación de Datos

Normalización y Escalado

Ajustar variables a una escala común (0-1 o media=0, std=1)

Importancia: Algoritmos sensibles a la escala como KNN, SVM, redes neuronales

Codificación de Variables Categóricas

One-Hot Encoding: Crear columnas binarias para cada categoría

Label Encoding: Asignar números enteros a categorías

Detección de Outliers

Identificar valores atípicos que pueden distorsionar el modelo usando métodos estadísticos

Ingeniería de Características

Crear nuevas características a partir de las existentes para mejorar el rendimiento del modelo.

- Extraer información de fechas (día, mes, año)
- Crear variables de relación entre características
- Agregar datos de fuentes externas

03

Aprendizaje Supervisado Regresión

Predicción de valores continuos usando relaciones entre variables



Regresión Lineal Simple

Concepto Fundamental

La regresión lineal simple es el modelo más básico de ML supervisado. Predice una variable dependiente (y) a partir de una variable independiente (x) asumiendo una **relación lineal**.

Fórmula Matemática

$$y = \beta_0 + \beta_1 x$$

β_0 (Intercepto):

Valor de y cuando $x = 0$

β_1 (Pendiente):

Cambio en y por cada unidad de x

¿Cómo Funciona?

El algoritmo encuentra la **línea recta que mejor se ajusta** a los puntos de datos, minimizando la suma de los errores cuadráticos entre los valores reales y predichos (Método de Mínimos Cuadrados).

Supuestos del Modelo

- ✓ Relación lineal entre variables
- ✓ Independencia de observaciones
- ✓ Normalidad de residuales
- ✓ Homoscedasticidad (varianza constante)

Ejemplo Práctico

Predicción de Precios de Vivienda

Queremos predecir el precio de una casa basándonos en su tamaño en metros cuadrados.

Variable independiente (x): Tamaño en m^2

Variable dependiente (y): Precio en USD

Datos de Entrenamiento

Casa de 80 m^2 → \$120,000

Casa de 120 m^2 → \$180,000

Casa de 150 m^2 → \$225,000

Casa de 200 m^2 → \$300,000

Resultado del Modelo

$$\text{Precio} = 1500 \times (\text{Tamaño})$$

Predicción: Casa de 100 m^2 ≈ \$150,000

Otras Aplicaciones

💡 **Ventas vs. Publicidad:** Predecir ventas según inversión en marketing

💡 **Temperatura vs. Altitud:** Relación entre altura y temperatura



Regresión Lineal Múltiple

Ampliando el Concepto

La regresión lineal múltiple extiende el concepto simple usando **múltiples variables independientes** (x_1, x_2, \dots, x_n) para predecir la variable dependiente (y).

Fórmula Matemática

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Cada coeficiente β_i representa el cambio en y por cada unidad de cambio en x_i , manteniendo las demás variables constantes (ceteris paribus).

Ventajas

- + Captura relaciones más **complejas y realistas**
- + Mejora la **precisión predictiva** al usar más información
- + Permite identificar qué variables tienen **mayor impacto**

Ejemplo Práctico Detallado

Predicción Avanzada de Precios de Vivienda

Ahora predecimos el precio usando **múltiples características**:

x_1 : Tamaño (m²)

x_2 : Ubicación (1-10)

x_3 : N° Habitaciones

x_4 : Antigüedad (años)

Modelo Resultante (Ejemplo)

$$\begin{aligned} \text{Precio} = & 10,000 + 1,200 \times (\text{Tamaño}) \\ & + 15,000 \times (\text{Ubicación}) \\ & + 8,000 \times (\text{Habitaciones}) \\ & - 500 \times (\text{Antigüedad}) \end{aligned}$$

Interpretación de Coeficientes

- Cada m² adicional aumenta precio en **\$1,200**
- Cada punto de ubicación suma **\$15,000**
- Cada habitación extra agrega **\$8,000**
- Cada año de antigüedad resta **\$500**



Evaluación de Modelos de Regresión

¿Por Qué Evaluar?

Necesitamos métricas objetivas para medir qué tan bien nuestro modelo predice valores nuevos. La evaluación nos permite **comparar diferentes modelos** y seleccionar el mejor.

Métricas Principales

MAE - Error Absoluto Medio

Promedio de diferencias absolutas entre valores reales y predichos

MAE = 5000

Interpretación: En promedio, nos equivocamos en \$5,000

RMSE - Raíz del Error Cuadrático Medio

Penaliza errores grandes (eleva al cuadrado antes de promediar)

RMSE = 7500

Interpretación: Error típico de \$7,500, da más peso a predicciones muy erróneas

R² - Coeficiente de Determinación

Indica el **porcentaje de varianza** en la variable dependiente que es explicada por el modelo. Varía entre 0 y 1.

0.85

R² = 85%

El modelo explica el 85% de la variabilidad

El 15% restante es error/noise

Guía de Interpretación

- R² < 0.5: Modelo débil
- 0.5 ≤ R² < 0.8: Modelo aceptable
- R² ≥ 0.8: Modelo fuerte

Mejores Prácticas

- ✓ **Usar múltiples métricas:** Ninguna métrica es suficiente por sí sola
- ✓ **Validación cruzada:** Evaluar en datos no usados en entrenamiento
- ✓ **Contexto:** Interpretar métricas según el problema específico

04

Aprendizaje No Supervisado Clustering

Descubriendo grupos naturales en datos sin etiquetas

Clustering y Algoritmo K-Means

¿Qué es el Clustering?

El clustering es una técnica de aprendizaje no supervisado que **agrupa datos similares** en conjuntos llamados **clústeres**, sin necesidad de etiquetas previas.

Objetivo Principal

Maximizar la **similitud dentro del clúster** (intra-cluster) y minimizar la similitud entre **diferentes clústeres** (inter-cluster).

Tipos de Clustering

Particionado

Divide datos en K grupos no superpuestos (K-Means)

Jerárquico

Construye árbol de clústeres anidados

Algoritmo K-Means

El algoritmo más popular. El usuario especifica **K** (número de clústeres).

Proceso Iterativo

1. Inicializar K centroides aleatoriamente
2. Asignar cada punto al centroide más cercano
3. Recalcular centroides como promedio de puntos
4. Repetir hasta convergencia

Aplicaciones Reales

Marketing

Segmentación de clientes para campañas dirigidas

Finanzas

Detección de transacciones fraudulentas

Entretenimiento

Sistemas de recomendación (Netflix, Spotify)

Logística

Optimización de rutas de entrega

Manufactura

Mantenimiento predictivo de maquinaria

Ventajas y Limitaciones

Ventajas

- Simple y rápido
- Escala bien

Limitaciones

- Necesita especificar K
- Sensibilidad a inicialización

REGISTER

LOGIN

ABOUT

FAQ



05

DATA VISUALIZATION

Ética en Machine Learning

Construyendo sistemas de IA responsables y justos





Sesgos en Datos y Algoritmos

¿Qué es el Sesgo en ML?

El **sesgo** es un **error sistemático** que produce resultados injustos para ciertos grupos, perpetuando o amplificando discriminaciones existentes.

Origen de los Sesgos

1. Sesgo en los Datos

Datos desbalanceados o históricos

2. Sesgo Algorítmico

Elecciones de diseño que amplifican sesgos

Tipos de Sesgo en Datos

Sesgo de Representación

Grupos subrepresentados en datos de entrenamiento

Sesgo Histórico

Datos reflejan prácticas discriminatorias del pasado

Sesgo de Medición

Variables usadas como proxy no representan bien el concepto

Ejemplos Reales Documentados

COMPAS - Justicia Criminal

Sistema de predicción de reincidencia usado en tribunales de EE.UU.

Sesgo encontrado: Falsos positivos 2x más altos para afroamericanos

Amazon - Reclutación

Herramienta de IA para filtrar currículos (2018)

Sesgo encontrado: Penalizaba currículos con palabras relacionadas con mujeres

Reconocimiento Facial

Sistemas de grandes tecnológicas

Sesgo encontrado: Error 35% mayor para mujeres de color vs. hombres blancos

Consecuencias del Sesgo

⚠ **Impacto humano:** Decisiones injustas afectan vidas y oportunidades

⚡ **Riesgos legales:** Demandas y regulaciones como el AI Act europeo

⟳ **Pérdida de confianza:** Usuarios rechazan sistemas percibidos como injustos



Implicaciones Éticas y Responsabilidad

Transparencia

Los usuarios deben entender **cómo** se toman las decisiones automáticas.

Derecho a la explicación: Poder explicar por qué el modelo tomó una decisión específica

Equidad

Los algoritmos deben tratar a todos los grupos de manera **justa**.

Igualdad de oportunidades: Mismo rendimiento para todos los grupos demográficos

Rendición de Cuentas

Debe haber **mecanismos** para cuestionar decisiones incorrectas.

Canales de apelación: Procesos para corregir errores del sistema

Privacidad

Protección de datos **personales** y sensibles.

Protección de datos: Cumplir regulaciones como GDPR

Beneficencia

La IA debe **maximizar beneficios** y minimizar daños.

Impacto positivo: Usar IA para resolver problemas sociales reales

¿Por Qué la Ética Es Estratégica?

Construye Confianza

Usuarios confían en sistemas percibidos como justos y transparentes

Mitiga Riesgos

Evita daños reputacionales, legales y financieros

Ventaja Competitiva

Diferencia la empresa como líder en IA responsable

Mejores Prácticas

Auditar Regularmente

Evaluar modelos en producción para detectar sesgos emergentes

Datos Diversos

Usar datasets representativos de todas las poblaciones

Equidad como Objetivo

Incorporar métricas de fairness en el entrenamiento

Diversidad de Equipos

Incluir perspectivas diversas en el diseño y desarrollo



Construyendo el Futuro de la Inteligencia Artificial

El Machine Learning es una herramienta **poderosa** que está transformando nuestro mundo.

Como futuros profesionales, tienen la **responsabilidad** de desarrollar sistemas no solo inteligentes, sino también **éticos, justos y beneficiosos** para toda la sociedad.

La clave del éxito está en combinar **conocimiento técnico** con **pensamiento crítico** y **conciencia ética**.

— ¡Gracias por su atención! —